Resumen de papers revisados

Renzo Dacillo [3]
•**Artículo:** Transparent and bias-resilient AI framework for recidivism prediction using deep learning and clustering techniques in criminal justice.
•**Autores:** Muhammed Cavus, Muhammed Nurullah Benli, Usame Altuntas, Mahmut Sari, Huseyin Ayan & Yusuf Furkan Ugurluoglu
•**Revista:** Applied Soft Computing Journal (April 2025)
•Cavus, M. (2025). Transparent and bias-resilient AI framework for recidivism prediction using deep learning and clustering techniques in criminal justice. ScienceDirect. Applied Soft Computing Journal. DOI: https://doi.org/10.1016/j.asoc.2025.113160

Objetivo y datos

Paper que trata de predecir la reincidencia de internos, para ello se usa un dataset de 49,446 individuos sacado de *California Megan's Law website*, se menciona quel a reincidencia de internos desgasta la confianza en la sociedad y fractura el propio tejido social, además que los costos del estado para cada recluso cada año en estados unidos se encuentra entre 30000 y 60000 dólares generando una carga financiera. Estos problemas demandan un modelo que pueda predecir la reincidencia de reclusos considerando:

•Principio de individualización de la pena: consideración de características únicas e individuales del caso
•Principio de transparencia y rendición de cuentas: Acusados deben poder comprender cómo los resultados de la IA influencian su sentencia.
•Principio de no discriminación y mitigación de sesgos: Requerimiento para el uso de la IA en los sistemas de justicia, adherencia al principio de no discriminación evitando sesgos potenciales.
•Principio de presunción de inocencia y exactitud: "it is better that ten guilty persons escape than that one innocent suffer".

Modelos y resultados

Para ello, se utilizan técnicas de clustering (K-means), IA explicativa (SHAP), evitar features demográficos que sesguen el modelo y aumentar el accuracy (para evitar falsos positivos) respectivamente. El entrenamiento de la red neuronal por cada cluster, usa PCA (Análisis de componentes principales) para reducir la dimensionalidad y SMOTE para balancear los datos. A todas estas técnicas, el autor lo llama *Recidivism clustering Network (RCN)* y explica que es más completo que modelos actuales de reincidencia como *COMPAS*. El dataset lo ha dividido en 80% para entrenamiento y 20% para validación, el accuracy obtenido fue del 75%.

TRANSPARENT AND BIAS-RESILIENT AI FRAMEWORK FOR RECIDIVISM PREDICTION USING DEEP LEARNING AND CLUSTERING TECHNIQUES IN CRIMINAL JUSTICE

Aplicación	Clasificación
Problema	• La reincidencia de internos **desgasta la confianza en la sociedad** y fractura el propio tejido social • Los **costos del estado** para cada recluso cada año en estados unidos se encuentra entre 30000 y 60000 dólares generando una carga financiera. (problema económico)
Datos	• 49,446 individuos • **Historia:** Descripción del crimen, año de la última condena, año de la última liberación. • **Detalles demográficos:** Año de nacimiento, etnia, color de ojos, color de cabello, estatura, peso.
Modelo	Redes neuronales, métodos de clustering (k-means) e IA explicable (SHAP)
Resultado	Predicción de reincidencia, con contribuciones de los features para explicabilidad

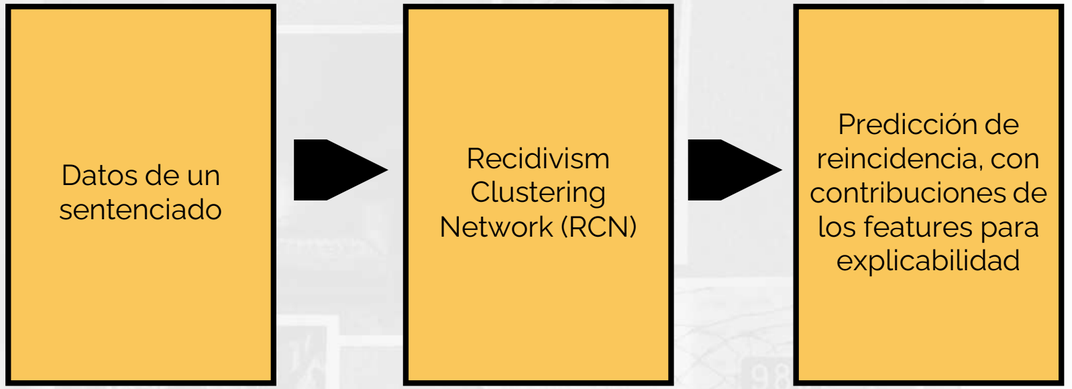


Table 3
Descriptive statistics of offender characteristics and criminal history.

	Year of last conviction	Year of last release	Height	Weight	Age
Count	3920	3920	49 446	49 446	49 446
Mean	1994.14	1996.62	69.10	191.63	61.84
Std	9.94	10.13	3.27	42.35	14.12
Min	1945	1949	24	75	26
25%	1988	1990	67	162	52
50%	1994	1997	69	185	62
75%	2002	2005	71	212	71
Max	2015	2100	86	600	118

80 entrenamiento, 20 validación

TRANSPARENT AND BIAS-RESILIENT AI FRAMEWORK FOR RECIDIVISM PREDICTION USING DEEP LEARNING AND CLUSTERING TECHNIQUES IN CRIMINAL JUSTICE

Metodología



Limitaciones:

1)Distribución de reincidentes con no reincidentes está desbalanceada

2) Privacidad para acceder a datos personales más específicos.

3) Datasets de penitenciarios no está estandarizada.

.

Consideraciones:

1)Principio de individualización de la pena: consideración de características únicas e individuales del caso

2) Principio de transparencia y rendición de cuentas: Acusados deben poder comprender cómo los resultados de la IA influencian su sentencia.

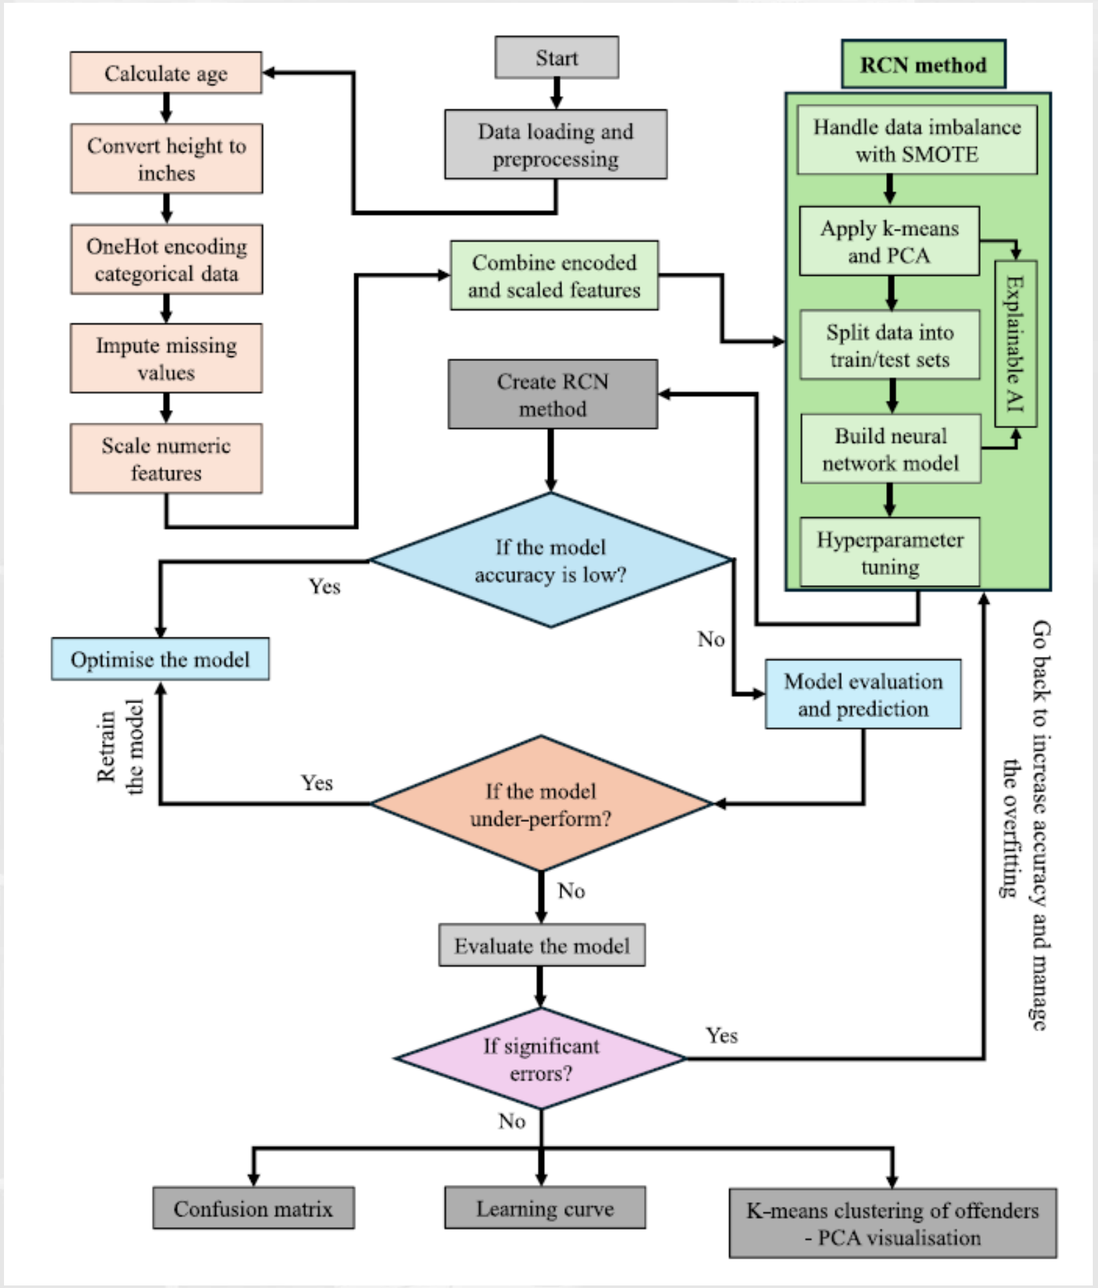
.

3)Principio de no discriminación y mitigación de sesgos: Requerimiento para el uso de la IA en los sistemas de justicia, adherencia al principio de no discriminación evitando sesgos potenciales.

4) Principio de presunción de inocencia y exactitud: ‘‘it is better that ten guilty persons escape than that one innocent suffer’’.

.

TRANSPARENT AND BIAS-RESILIENT AI FRAMEWORK FOR RECIDIVISM PREDICTION USING DEEP LEARNING AND CLUSTERING TECHNIQUES IN CRIMINAL JUSTICE



Metodología de entrenamiento

Métodología:

1) Preprocessing: One-hot encoding, cálculos de transformación de unidades y años.

2) SMOTE (Synthetic Minority Over-sampling Technique)

3) PCA (Análisis de componentes principales)

4) K-means

5) Entrenar red neuronal para cada clúster

6) Evaluar modelo

7) Mostrar resultados (t-SNE, k-means, SHAP)

Resultados:
Accuracy:
75%

